AP2026 · Grupo MEI-2

Classificação de Texto Human vs. AI

Fontes de Dados

Dataset v1 (*datasets* públicos)

- **OpenTuringBench** (MLNTeam-Unical)
  textos de LLMs para as classes Meta e Google
- **HC3** (Hello-SimpleAI)
  humano vs. ChatGPT
- **Anthropic/persuasion**
  textos de modelos Anthropic

Dataset v2 (geração sintética)

- **Groq API**
  Meta (llama-3.3-70b) + OpenAI (gpt-oss-120b)
- **Ollama** (execução local)
  Google (gemma3:1b)
- **Claude**
  Anthropic (Haiku 4.6)
- **Wikipedia API**
  Human (parágrafos de artigos)

150	37	3	111
textos/classe	tópicos científicos	templates de prompt	combinações

Pré-processamento e Splits

Pré-processamento

Limpeza: *lowercase*, remoção de pontuação

Truncagem: 80–120 palavras (truncate_text())

Deduplicação: remoção por conteúdo duplicado

Balanceamento: máx. 1000 amostras/classe

Divisão Estratificada (v2)

split	amostras	%
treino	3 500	**70%**
validação	750	**15%**
teste	750	**15%**

Estimação do Erro

Validação com o dataset-exemplos.csv (125 exemplos reais do docente). Nos transformers, dados reais sobre-amostrados ×9–15 no treino.

Modelos e Arquiteturas

Submissão 1: Modelos Clássicos

Subm1-A: Regressão Logística

NumPy

***Vectorizer*:** TF-IDF (10K vocab, *uni-grams*)

Classificador: *softmax* multi-classe + L2

***Optimizer*:** SGD batch

***Learning rate*:** 0.1

***Epochs*:** 300

Subm1-B: DNN em PyTorch

CombinedVectorizer

***Features*:** 5K *word* + 3K *char n-grams* → 8K

Arquitectura: 8K → [128] → ReLU → Drop(0.5) → [64] → [5]

***Optimizer*:** Adam, lr=0.001

***Epochs*:** 100 (*early stop*, patience=15)

Submissão 2: Transformers

Subm2-B: DistilRoBERTa

Max. tokens: 128 | ***Batch***: 32

Epochs: 15, *early stop patience*=3

lr=3e-5 | *label smoothing*=0.1 | *warmup*=10%

Dados: 5000 sintéticos + 100 reais × 10

Subm2-A: RoBERTa-base

Max. tokens: 128 | ***Batch***: 32

Epochs: 20, *early stop patience*=5

mixed precision (FP16) + *gradient clipping* (1.0)

Dados: 5000 sintéticos + 100 reais × 9

Optimização via Optuna (10 *trials*, MedianPruner)

hiperparâmetro	espaço de busca	melhor valor
learning rate	[1e-5,5e-5] *log*	**1.10e-5**
batch size	{16,32}	**32**
label smoothing	[0.05,0.2]	**0.062**
warmup fraction	[0.05,0.2]	**16.2%**
weight decay	[1e-3,0.1] *log*	**0.0151**
real data weight	[5,20]	**9**

Resultados

Resultados Internos e Externos

modelo	*accuracy* interna	*accuracy* externa	submissão
LogReg em NumPy	—	~32%	Subm1-A
DNN em PyTorch	-	~32%	Subm1-B
DNN v2	58%	-	-
DistilRoBERTa	67%	58%	Subm2-B
RoBERTa-base + Optuna	**76%**	**67%**	**Subm2-A**

Trabalho Futuro

Submissão 3

Ensemble
RoBERTa + DNN combinados

Dados
mais tópicos e mais textos por modelo

DeBERTa
explorar outros transformers

Fine-tuning
com todos os dados disponíveis